第3课 项目实操：下厨房项目

一、课程结构导图

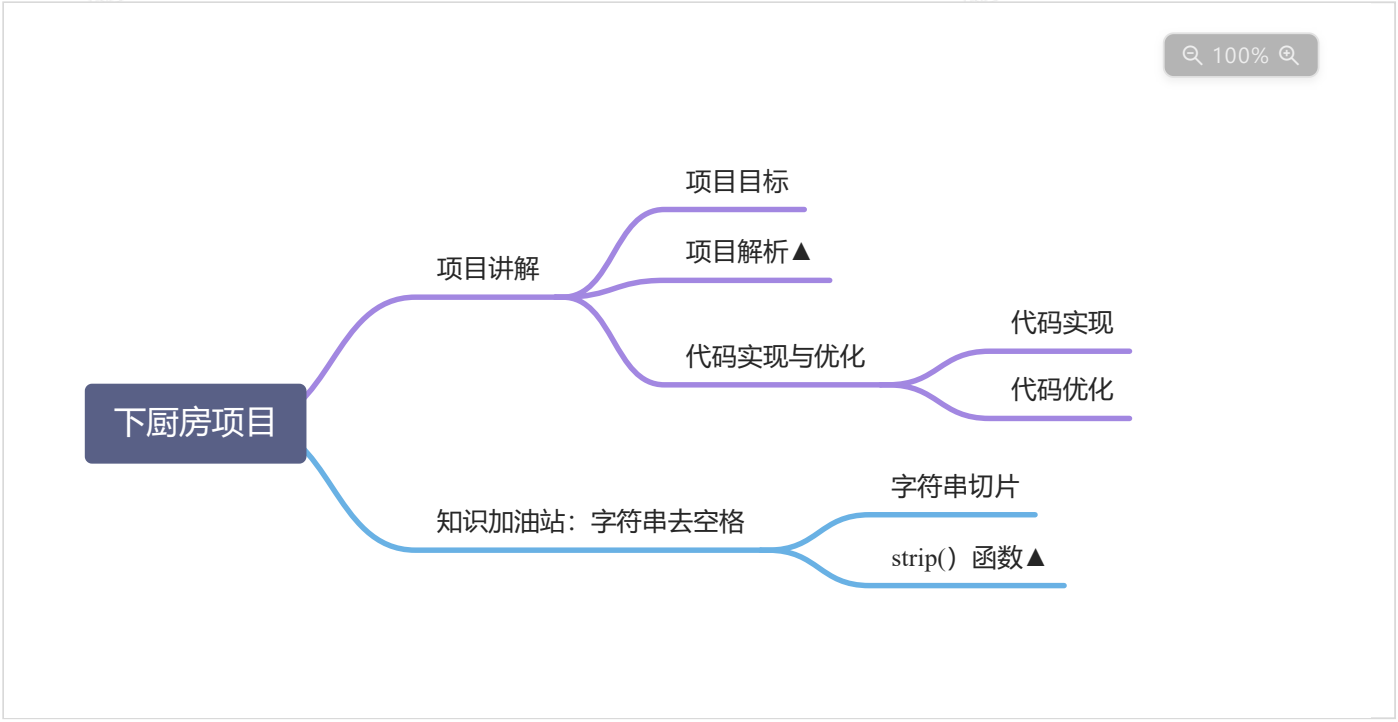

注：▲为重点知识点。

二、项目讲解

2.1 项目目标

爬取目标：爬取热门菜谱清单，内含：菜名、原材料、详细烹饪流程的URL。

目标网址：http://www.xiachufang.com/explore/ <http://www.xiachufang.com/explore/>

2.2 项目解析

- **查看网页的robots协议**

1. 先明确需要爬取的数据所在的网页，然后查看该网页的robots协议，确认哪一些数据可以爬取。

2. 在根目录加上robots.txt查看协议，确认 /explore/ 不在禁止爬取的列表内。

- **获取数据**

使用requests.get()发起请求，获取网页数据。使用status_code属性查看是否请求成功。请求成功之后，使用text属性把相应的网页内容传给BeautifulSoup4库进行解析。

- **解析网页**

打开检查工具，通过小箭头进行定位，查看数据所在的标签（多查找几个找到共同规律）。

菜名和详细烹饪流程的URL：

通过定位可以发现，这些数据都在<p class="name">标签下的<a>标签中，菜名是<a>标签内的文本，URL是<a>标签里属性href的值，不过这里的url只是一部分网址，需要复制前半部分网址做拼接才能得到完整的网址。而且<p class="name">的个数刚好和左边菜名的个数一致，都是25个。

原材料：

通过定位可以发现，原材料的数据都在<p class="ing ellipsis">标签下的所有标签中，而且该标签的数量和菜名的数量相同（和URL查找方法一样）。

共同的父级标签：

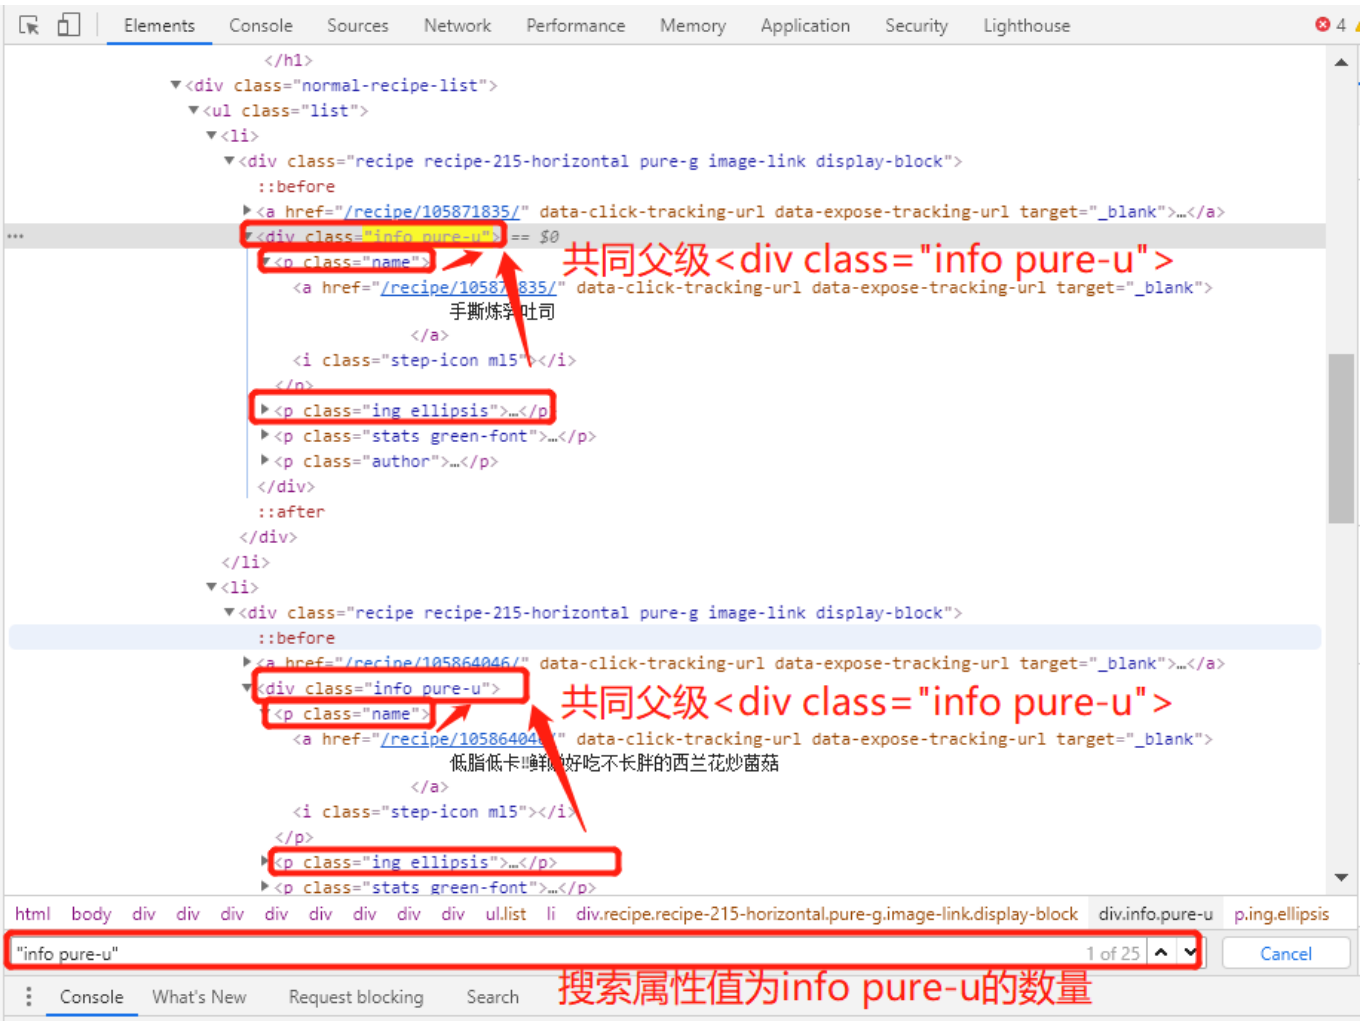

在藏有需要爬取的数据中的两个标签：<p class="name">和<p class="ing ellipsis">中，我们往上一级查看，发现数据有一个共同的父级标签 ，而且该标签的数量和菜名的数量相同。

- **提取数据**

找到了数据的藏身之处之后，我们可以开始爬取试试。基于刚刚的分析，我们产生了两种写爬虫的思路：

思路一：我们先去爬取所有的最小父级标签 ，然后针对每一个父级标签，提取里面的菜名、URL、食材；

思路二：我们分别提取所有的菜名、所有的URL、所有的食材。然后让菜名、URL、食材给一一对应起来（这并不复杂，第0个菜名，对应第0个URL，对应第0组食材，按顺序走即可）。

- **存放数据**

写一个for循环，将爬取到的数据都存放到列表中。

2.3 代码实现与优化

2.3.1 代码实现

- **解法一：提取最小父级标签，取出每一组的数据。**
  - 获取和解析网页数据；

```
# 引用requests库
import requests
# 引用BeautifulSoup库
from bs4 import BeautifulSoup

# 获取数据
res_foods = requests.get('http://www.xiachufang.com/explore/')
# 解析数据
bs_foods = BeautifulSoup(res_foods.text,'html.parser')
```

  - 提取数据（该部分代码和上面代码组合才可正常运行）；

```
# 查找最小父级标签
list_foods = bs_foods.find_all('div',class_='info pure-u')

# 提取第0个父级标签中的<a>标签
tag_a = list_foods[0].find('a')
name = tag_a.text   # 菜名
URL = 'http://www.xiachufang.com'+tag_a['href'] # 获取URL

# 提取第0个父级标签中的<p>标签
tag_p = list_foods[0].find('p',class_='ing ellipsis')
ingredients = tag_p.text    # 食材

print([name,URL,ingredients])   # 打印菜名、URL、食材
```

  - 利用循环遍历提取所有数据，将每一组数据取出，作为一个小列表存放到大列表中。

```
# 创建一个空列表，用于存储信息
list_all = []

for food in list_foods:
    tag_a = food.find('a')      # 提取第0个<a>标签
    name = tag_a.text           # 菜名
    URL = 'http://www.xiachufang.com'+tag_a['href']     # 获取URL
    tag_p = food.find('p',class_='ing ellipsis')        # 提取第0个父级标签中的<p>标签
```

```
    ingredients = tag_p.text    # 食材
    list_all.append([name,URL,ingredients]) # 将菜名、URL、食材，封装为列表，添加进list_all

print(list_all) # 打印所有信息
```

- **解法二：分别提取所有的菜名、URL和食材的数据，再一一对应拼接。**
  - 获取和解析网页数据（同解法一）；
  - 分别提取所有数据；

```
# 查找包含菜名和URL的<p>标签
tag_name = bs_foods.find_all('p',class_='name')
# 查找包含食材的<p>标签
tag_ingredients = bs_foods.find_all('p',class_='ing ellipsis')
```

  - 利用循环遍历提取所有数据，将每一组数据进行拼接，作为一个小列表存放到大列表中。

```
list_all = []       # 创建一个空列表，用于存储信息

for x in range(len(tag_name)):  # 启动一个循环，次数等于菜名的数量
    name = tag_name[x].text     # 菜名
    URL = tag_name[x].find('a')['href']     # 链接
    ingredients = tag_ingredients[x].text   # 食材
    list_all.append(list_food)  # 将菜名、URL、食材，封装为列表，添加进list_all

print(list_all)     # 打印所有信息
```

- **两种解法对比：**
  - 如果我们需要爬取的数据，在网站上每一组数据中的每一个数据都只有一个，不多出也不缺失，那么，这两种方法都可以使用，没有差别。
  - 但是在实际的应用中，因为网站的数据本身可能存在一些缺陷，可能会有一些数据确实或者某一个数据不止一个，会使得匹配的数据出现错位。找出每一类数据然后一一对应匹配的错误率会比较高，而找出每一个父级标签，可以比较好的控制这样的错误。所以实战中更推荐使用通过最小父级标签来爬取数据。

2.3.2 代码优化

代码打印的结果存在很多空格和换行符，需要对这些内容进行一个处理，下面利用两种方法来分别处理。

- **使用字符串切片**
  - 菜名

- 方法一：通过在网页端双击属性值计算。

- 方法二：复制字符串，使用len()函数+三引号来计算。

```
print(len('''
                手撕炼乳吐司
            '''))
print(len('''
                '''))    # 字符前的空格/换行符, 共17
print(len('''
            '''))        # 字符后的空格/换行符, 共13
```

- 代码做以下修改（注：解法二是在父级<p>往下取子级<a>的内容，所以需要多切去两边的一个空格。）

解法一：

name = tag_a.text

↓

name = tag_a.text[17:-13]

解法二：

tag_name[x].text

↓

tag_name[x].text[18:-14]

- 食材：在父级往下取子级的内容时，会在两端各多出一个空行，需要把它切去。

解法一：

ingredients = tag_p.text

↓

ingredients = tag_p.text[1:-1]

解法二：

tag_ingredients[x].text

↓

tag_ingredients[x].text[1:-1]

- **使用strip()函数**

- 菜名

解法一：

name = tag_a.text

name = tag_a.text.strip()

解法二：

tag_name[x].text

tag_name[x].text.strip()

- 食材

解法一：

ingredients = tag_p.text

ingredients = tag_p.text.strip()

解法二：

tag_ingredients[x].text

tag_ingredients[x].text.strip()

- **优化后代码如下：**
  - 解法一：查找最小父级标签，再将每一组数据提取出来。

```
# 引入模块
import requests
from bs4 import BeautifulSoup
# 获取数据
url = 'http://www.xiachufang.com/explore'
# 定义请求头，伪装为浏览器，放在get()前面即可。
headers={'user-agent':'Mozilla/5.0 (Macintosh; Intel Mac OS X 10_13_6) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/71.0.3578.98 Safari/537.36'}
# 把headers传递给get()函数的headers参数，获取数据
res_foods = requests.get(url,headers = headers)

# 解析数据
bs_foods = BeautifulSoup(res_foods.text,'html.parser')
# 提取数据
list_foods = bs_foods.find_all('div',class_='info pure-u')  # 获取最小父级标签
list_all = []
for food in list_foods:
    tag_a = food.find('a')
    name = tag_a.text[17:-13]
    URL = 'http://www.xiachufang.com'+tag_a['href']
    tag_p = food.find('p',class_='ing ellipsis')
    ingredients = tag_p.text[1:-1]
```

```
    # 存储数据
    list_all.append([name,URL,ingredients])

print(list_all)     # 打印所有信息
```

- 解法二：分别提取所有的菜名、URL和食材的数据，再一一对应拼接。

```
import requests
from bs4 import BeautifulSoup
# 获取数据
url = 'http://www.xiachufang.com/explore'
# 定义请求头，伪装为浏览器，放在get()前面即可。
headers={'user-agent':'Mozilla/5.0 (Macintosh; Intel Mac OS X 10_13_6) AppleWebKit/537.36 (KHTML, li
# 把headers传递给get()函数的headers参数，获取数据
res_foods = requests.get(url,headers = headers)
# 解析数据
bs_foods = BeautifulSoup(res_foods.text,'html.parser')
# 提取数据，分别提取所有数据
tag_name = bs_foods.find_all('p',class_='name')
tag_ingredients = bs_foods.find_all('p',class_='ing ellipsis')
list_all = []
for x in range(len(tag_name)):
    name = tag_name[x].text[18:-14]
    URL = 'http://www.xiachufang.com'+tag_name[x].find('a')['href']
    ingredients = tag_ingredients[x].text[1:-1]
    # 存储数据
    list_all.append([name,URL,ingredients])

print(list_all)     # 打印所有信息
```


三、知识加油站：字符串去空格

3.1 字符串切片

概念：取出某个字符串中特定的部分。

语法：字符串[ ]；字符串切片和列表的切片原理是一样的。有正向取值和负向取值，都遵循左取右不取的规则。

示例：

```
content = '今晚吴枫下厨房，给大家做美食啦~'
print(content[2:4])     # 结果：吴枫
print(content[-4:-2])   # 结果：美食
print(content[2:-1])    # 结果：吴枫下厨房，给大家做美食啦
```

3.2 strip()函数

概念：是一个可以把字符串两端的空格和换行符去掉的函数。

语法：字符串.strip()。

示例：

```
content = '  \n学霸的笔记  '
print(content.strip())  # 结果：学霸的笔记
```